

Classificação de Saúde Fetal: Otimização e Interpretação de Algoritmos de Aprendizado de Máquina

Gabriel Ricci Pazinato

Mariana Burzlaff Ercolani

1 Coleta de Dados e Identificação do Problema

Este trabalho tem como propósito realizar o spot-checking de algoritmos de aprendizado de máquina vistos em sala de aula para o diagnóstico preditivo de saúde fetal. O principal objetivo é identificar a saúde do feto com base em exames de cardiotocografia (CTG). Portanto, a tarefa é de classificação multiclasse supervisionada.

Os dados utilizados foram selecionados na plataforma Kaggle¹ e contém atributos numéricos extraídos de exames de CTG, classificando a saúde fetal em três classes: Normal (1), Suspeito (2) e Patológico (3). Esta análise visa determinar quais algoritmos apresentam melhor baseline de desempenho na detecção de irregularidades, minimizando, assim, o risco de diagnósticos falsos negativos no quadro clínico de estudo.

2 Análise Exploratória e Pré-processamento de Dados

O objetivo desta parte do trabalho foi compreender as características dos dados selecionados. O conjunto original possui 2.126 instâncias, 21 atributos preditivos numéricos e 3 classes na variável alvo. Os atributos são obtidos através de métricas médicas extraídas do exame, como batimentos cardíacos fetais base (*baseline value*), número de acelerações, desacelerações, etc.

Não foram detectados valores faltantes, removendo a necessidade de utilizar técnicas de imputação de dados. Entretanto, como indicado na [Figura 1](#), pode-se observar um forte desbalanceamento da variável alvo. Também foram identificadas 13 linhas duplicadas, removidas durante a etapa de pré-processamento.

¹<https://www.kaggle.com/datasets/andrewmvd/fetal-health-classification>




Figura 1. A Classe 1 representa a vasta maioria das instâncias em comparação às classes 2 e 3.

Já para a análise exploratória de dados, foram extraídas as estatísticas de valor mínimo, médio e máximo, sumarizadas na [Tabela 1](#). Com isso, observou-se que elas possuem escala discrepante. Por exemplo, a variável *histogram variance* varia de 0 a 269, enquanto *accelerations* fica entre 0 e 0.0190.

A padronização foi incorporada ao fluxo de treinamento por meio de *pipelines* do `scikit-learn`. Dessa forma, em cada divisão dos dados, o *scaler* é ajustado apenas sobre o conjunto de treinamento e depois aplicado ao conjunto de validação ou teste. Essa escolha evita vazamento de dados entre os conjuntos e mantém o processo de avaliação mais consistente.

Tabela 1. Resumo estatístico dos atributos numéricos gerado na etapa de EDA.

Variável	Mínimo	Máximo	Média	Desvio Padrão
baseline value	106.0000	160.0000	133.3039	9.8408
accelerations	0.0000	0.0190	0.0032	0.0039
fetal_movement	0.0000	0.4810	0.0095	0.0467
uterine_contractions	0.0000	0.0150	0.0044	0.0029
light_decelerations	0.0000	0.0150	0.0019	0.0030
severe_decelerations	0.0000	0.0010	0.0000	0.0001
prolongued_decelerations	0.0000	0.0050	0.0002	0.0006
abnormal_short_term_variability	12.0000	87.0000	46.9901	17.1928
mean_value_of_short_term_variability	0.2000	7.0000	1.3328	0.8832
percentage_of_time_with_abnormal...	0.0000	91.0000	9.8467	18.3969
mean_value_of_long_term_variability	0.0000	50.7000	8.1876	5.6282
histogram_width	3.0000	180.0000	70.4459	38.9557
histogram_min	50.0000	159.0000	93.5795	29.5602
histogram_max	122.0000	238.0000	164.0254	17.9442
histogram_number_of_peaks	0.0000	18.0000	4.0682	2.9494
histogram_number_of_zeroes	0.0000	10.0000	0.3236	0.7061
histogram_mode	60.0000	187.0000	137.4520	16.3813
histogram_mean	73.0000	182.0000	134.6105	15.5936
histogram_median	77.0000	186.0000	138.0903	14.4666
histogram_variance	0.0000	269.0000	18.8081	28.9776
histogram_tendency	-1.0000	1.0000	0.3203	0.6108

Para a análise de potenciais outliers, plotou-se a distribuição de quartis dos atributos padronizados (Figura 2).




Figura 2. Boxplot dos atributos (padronizados via Z-score) evidenciando a distribuição e presença de outliers multivariados.

É perceptível uma quantidade expressiva de outliers em atributos como *percentage of time with abnormal long term variability* e nas taxas de desaceleração. Contudo, esses outliers foram mantidos, uma vez que valores extremos podem auxiliar na classificação de

fetos patológicos e a sua remoção poderia enviesar o modelo contra a classe minoritária de maior interesse preditivo.

Pela discrepância dos intervalos de diferentes atributos, como identificado na [Tabela 1](#), aplicou-se o *StandardScaler* a todo pipeline, garantindo assim que métodos sensíveis a distância não sofram viés por isso.

3 Definição da Abordagem, Algoritmos e Estratégias de Avaliação

Para atender ao propósito do *spot-checking*, foram selecionados algoritmos diversos de classificação, buscando contemplar diferentes vieses indutivos. Os modelos avaliados incluem um método baseado em instâncias, KNN; modelos baseados em árvores e *ensembles*, como Árvore de Decisão, *Random Forest*, *Gradient Boosting*, *AdaBoost*, um classificador por *Stacking*; Regressão logística e uma Rede Neural do tipo MLP.

A [Tabela 2](#) resume os algoritmos selecionados e o tipo de estratégia de aprendizado representada por cada um.

Tabela 2. Algoritmos selecionados para a etapa de comparação inicial.

Algoritmo	Categoria
KNN	Baseado em instâncias
Árvore de Decisão	Modelo baseado em regras
Random Forest	Ensemble baseado em árvores
Gradient Boosting	Ensemble por boosting
AdaBoost	Ensemble por boosting
Stacking ²	Ensemble por combinação de modelos
Regressão Logística	Modelo linear
MLP	Rede Neural

A estratégia de avaliação adotada combinou uma separação inicial entre treino e teste com validação cruzada no conjunto de treino. Inicialmente, os dados foram divididos em 80% para treinamento e 20% para teste, utilizando amostragem estratificada para preservar a proporção das classes. A distribuição das classes é desbalanceada, como mostrado na [Figura 1](#), o que justifica o uso de estratificação na divisão dos dados.

No conjunto de treino, foi aplicada validação cruzada estratificada com cinco partições. Essa estratégia permite estimar o desempenho médio dos modelos de forma mais robusta do que uma única divisão treino-validação, mantendo a proporção das classes em cada partição. Além disso, foi definido um valor fixo de `random_state` nos procedimentos aleatórios, garantindo maior reprodutibilidade dos experimentos.

As métricas utilizadas para avaliação foram acurácia, *recall*, F1-score e F2-score. A escolha por essas métricas, utilizando a agregação **macro**, se deve ao desbalanceamento entre as classes, pois essa forma de agregação atribui o mesmo peso a cada classe no cálculo final. Como critério principal de comparação entre os modelos, foi adotado o F2-score macro, que dá maior peso ao *recall* do que à precisão. Essa escolha é adequada ao contexto do problema, pois falhas em identificar corretamente classes associadas a maior risco fetal podem ser mais prejudiciais do que falsos positivos.

²Modelo de Stacking baseado em Random forest e Gradient Boosting

4 Spot-checking de Algoritmos

Para a execução do *Spot-checking*, o treinamento foi repetido em 5 *folds* para cada algoritmo com configurações simples, sem otimização de hiperparâmetros. Visando garantir consistência e reprodutibilidade nos experimentos, fixou-se o *random state*=42. Desta forma, todos os modelos foram testados na mesma divisão de dados. A Figura 3 representa a sumarização de desempenho dos modelos ao longo dos 5 *folds*.




Figura 3. Boxplot dos modelos após processo de cross-validation

Como esperado, modelos de famílias diferentes obtiveram comportamentos distintos. Os modelos *ensembles* de árvores, principalmente *Gradient Boosting* e o *Random Forest*, obtiveram um desempenho basal superior aos demais. Nesses algoritmos, o principal ponto positivo é a menor variância entre os *folds*, indicando estabilidade preditiva para diferentes amostras de dados.

Por outro lado, algoritmos como *Decision Trees* simples mostraram caixas maiores no gráfico, um indicativo de forte sensibilidade ao conjunto de treinamento. As matrizes de confusão na Figura 4 geradas sobre o conjunto validado fortalecem essa observação, deixando em evidência onde os erros de classificação ocorrem entre as classes.

Tabelas com valores numéricos acerca do desempenho dos modelos encontram-se no apêndice deste documento.




Figura 4. Matrizes de confusão dos 8 modelos treinados

Portanto, os modelos *ensembles* de árvores superam os modelos linear e baseados em instâncias ao identificar a classe Patológica, nossa classe de maior interesse. Em resumo, os algoritmos mais promissores foram *Gradient Boosting* e o *Random Forest* para o problema de classificação escolhido, pois possuem ótimos equilíbrios entre estabilidade estatística e excelentes $f2\text{-score}$, sendo então as escolhas ideais para o avanço das investigações na próxima etapa.

Também vale destacar que o classificador linear demonstrou boa sensibilidade, enquanto modelos como random forest e gradient boosting tiveram poucos falsos positivos, o que possibilita a exploração de mais variações de *ensemble* baseados nestes classificadores.

5 Otimização de Hiperparâmetros

A partir dos resultados obtidos no *spot-checking*, foram selecionadas as abordagens de *Random Forest* e *Gradient Boosting* para a etapa de otimização de hiperparâmetros. Além disso, foi construída uma arquitetura de *Stacking Classifier*, combinando as previsões desses dois modelos em um meta-estimador linear baseado em Regressão Logística. A escolha dessas estratégias se justifica pelo desempenho superior dos modelos de *ensemble* na etapa anterior.

A métrica principal utilizada para a otimização foi o F2-Score Macro, mantendo consistência com a estratégia de avaliação definida anteriormente. Essa métrica atribui maior peso ao *recall*, sendo adequada ao objetivo de reduzir falsos negativos em classes associadas a maior risco fetal.

Visando alcançar bom desempenho preditivo sem recorrer a uma busca exaustiva demasiadamente ampla, a otimização foi organizada em uma etapa de exploração global seguida de ajuste fino local. A [Tabela 3](#) resume a estratégia utilizada para cada modelo.

Tabela 3. Configuração da otimização de hiperparâmetros realizada no T2.

Modelo	Estratégia de busca	Hiperparâmetros avaliados
Random Forest	<i>RandomizedSearchCV</i> com 120 configurações, seguido de <i>GridSearchCV</i> em grade refinada	Número de árvores, critério de divisão, profundidade máxima, mínimo de amostras para divisão, mínimo de amostras por folha, número de atributos considerados por divisão e ponderação das classes.
Gradient Boosting	<i>RandomizedSearchCV</i> com 160 configurações, seguido de <i>GridSearchCV</i> em grade refinada	Número de estimadores, taxa de aprendizado, profundidade máxima, mínimo de amostras para divisão, mínimo de amostras por folha, fração de amostras por etapa de <i>boosting</i> , número de atributos considerados e função de perda.
Stacking (RF + GB)	<i>GridSearchCV</i> sobre o meta-modelo e a estrutura de combinação	Parâmetro de regularização da Regressão Logística final, uso ou não das variáveis originais junto às predições dos modelos base (passthrough) e número de divisões internas de validação cruzada.

As melhores configurações obtidas ao final da busca estão sumarizadas na [Tabela 4](#). Para o *Stacking*, os modelos base utilizados foram as versões otimizadas do *Random Forest* e do *Gradient Boosting*.

Tabela 4. Melhores configurações encontradas para os modelos otimizados.

Modelo	Melhor configuração
Random Forest	<code>class_weight=balanced_subsample</code> , <code>criterion=entropy</code> , <code>max_depth=12</code> , <code>max_features=None</code> , <code>min_samples_leaf=8</code> , <code>min_samples_split=2</code> , <code>n_estimators=200</code> .
Gradient Boosting	<code>learning_rate=0.1</code> , <code>loss=log_loss</code> , <code>max_depth=5</code> , <code>max_features=sqrt</code> , <code>min_samples_leaf=1</code> , <code>min_samples_split=4</code> , <code>n_estimators=500</code> , <code>subsample=0.85</code> .
Stacking (RF + GB)	<code>cv=3</code> , <code>final_estimator__C=0.05</code> , <code>passthrough=False</code> .

5.1 Prevenção de *Data Leakage*

Para garantir a validade da metodologia, as linhas duplicadas foram removidas antes da divisão entre treino e teste, evitando que instâncias idênticas aparecessem simultaneamente nos dois conjuntos e inflassem artificialmente o desempenho.

Além disso, todas as etapas de pré-processamento foram encapsuladas em objetos *Pipeline* do *scikit-learn*. Dessa forma, o *StandardScaler* foi ajustado exclusivamente sobre os dados de treino em cada divisão da validação cruzada, sendo depois aplicado ao

respectivo conjunto de validação. O mesmo princípio foi mantido na avaliação final, em que o conjunto de teste permaneceu isolado até a seleção das melhores configurações.

Essa organização evita vazamento de dados, pois estatísticas como média e desvio padrão dos atributos não são calculadas com informações do conjunto de validação ou teste. Esse cuidado é especialmente importante porque os atributos possuem escalas muito distintas, como observado na etapa de análise exploratória.

No treinamento do *Stacking*, os estimadores base otimizados foram utilizados como modelos não ajustados dentro da nova arquitetura. O próprio *StackingClassifier* realiza o treinamento dos modelos base e do meta-estimador por meio de validação cruzada interna no conjunto de treino, evitando que o meta-modelo seja ajustado a partir de previsões produzidas sobre dados de teste.

O comportamento dos modelos durante a otimização está resumido na [Figura 5](#). Observa-se que as configurações de *Random Forest*, *Gradient Boosting* e *Stacking* alcançaram valores próximos de F2-Score Macro durante a validação cruzada. O melhor F2-Score Macro em validação cruzada foi obtido pelo *Stacking*, com 0.89200, seguido muito de perto pelo *Random Forest*, com 0.89195 quando arredondado a cinco casas decimais. O *Gradient Boosting* também apresentou bom desempenho, mas abaixo do esperado, com F2-Score Macro de 0.8901 após o ajuste fino.




Figura 5. Distribuição do F2-Score Macro durante as fases de busca aleatória e em grade.

Apesar da pequena vantagem do *Stacking* na validação cruzada, a diferença em relação ao *Random Forest* foi mínima. Portanto, a decisão final entre os modelos foi deixada para a comparação no conjunto de teste, apresentada na seção seguinte.

6 Comparação de Desempenho em Dados de Teste

Ao final da validação cruzada, as versões otimizadas dos modelos foram avaliadas no conjunto de teste isolado, correspondente a 20% dos dados. Esse conjunto não foi utilizado durante a busca de hiperparâmetros, sendo reservado apenas para a comparação final entre os modelos candidatos. A métrica principal permaneceu o F2-Score Macro, pois essa agregação atribui o mesmo peso às três classes e favorece o *recall*.

A [Tabela 5](#) apresenta os resultados obtidos no conjunto de teste, ordenados pelo F2-Score Macro. O *Random Forest* obteve o melhor desempenho segundo a métrica principal, com valor de 0.9236. O modelo de *Stacking* apresentou desempenho muito próximo, com valor de 0.9207, além de acurácia e F1-Score ligeiramente superiores. Ainda assim, como a prioridade definida para o problema foi maximizar o F2-Score Macro, o *Random Forest* foi selecionado como o modelo final. O *Gradient Boosting*, embora competitivo em acurácia, apresentou menor *recall* macro e, conseqüentemente, menor F2-Score Macro.

Tabela 5. Desempenho dos modelos otimizados no conjunto de teste.

Modelo	Acurácia	Recall Macro	F1 Macro	F2 Macro
Random Forest	0.9433	0.9341	0.9089	0.9236
Stacking (RF+GB)	0.9504	0.9239	0.9163	0.9207
Gradient Boosting	0.9504	0.8784	0.9051	0.8885

Essa relação também é ilustrada na [Figura 6](#), que compara graficamente as métricas de teste dos três modelos otimizados.



Figura 6. Comparação de desempenho dos modelos otimizados nos dados de teste.

Para aprofundar a análise do modelo escolhido, foram geradas curvas ROC e *Precision-Recall* para o *Random Forest*, utilizando a abordagem *One-vs-Rest* para as três classes da variável alvo. Essas curvas são apresentadas na [Figura 7](#).




Figura 7. Curvas ROC (esquerda) e Precision-Recall (direita) consolidadas para as três classes da variável alvo.

As curvas indicam que a classe 1 (Normal), por possuir maior número de exemplos, é a mais facilmente separada pelo modelo. Já as classes 2 (Suspeito) e 3 (Patológico), por serem minoritárias, apresentam maior sensibilidade ao desbalanceamento: à medida que o *recall* aumenta, a precisão tende a cair de forma mais acentuada. Esse comportamento reforça a escolha do F2-Score Macro como métrica principal, pois ele valoriza a capacidade de recuperar corretamente as classes de maior risco.

	Random Forest			Gradient Boosting			Stacking (Tuned RF+GB)		
Real	Normal	Suspeito	Patológico	Normal	Suspeito	Patológico	Normal	Suspeito	Patológico
Suspeito	7	51	0	13	44	1	7	50	1
Patológico	0	1	34	2	2	31	0	2	33
	Normal	Suspeito Predito	Patológico	Normal	Suspeito Predito	Patológico	Normal	Suspeito Predito	Patológico

Figura 8. Matrizes de Confusão no conjunto de teste.

A análise das matrizes de confusão (Figura 8) mostra que os modelos *Random Forest* e *Stacking* não classificaram nenhuma instância patológica como normal, isto é, não houve erros graves do tipo classe 3 predita como classe 1. No caso do *Random Forest*, a classe Patológica teve 34 instâncias corretamente classificadas e apenas uma instância classificada como Suspeita. Os erros restantes concentraram-se principalmente em confusões entre as classes Normal e Suspeita, com 11 instâncias da classe 1 preditas como classe 2, 5 instâncias da classe 1 preditas como classe 3 e 7 instâncias da classe 2 preditas como classe 1.

Assim, embora o *Stacking* tenha apresentado desempenho muito próximo e ligeira vantagem em acurácia e F1-Score, o *Random Forest* foi escolhido como modelo final por obter o maior F2-Score Macro no conjunto de teste e por ser mais simples, potencialmente mais fácil de interpretar. Por esse motivo, ele foi selecionado para a análise de interpretabilidade apresentada na próxima seção.

7 Interpretação do Melhor Modelo Treinado

Para interpretar o modelo final selecionado, foi analisado o *Random Forest*, vencedor da comparação em dados de teste pelo critério de F2-Score Macro. A análise concentrou-se principalmente na classe 3 (Patológico), por ser a classe de maior interesse clínico no contexto do problema. Foram utilizadas diferentes estratégias de interpretabilidade: valores SHAP, importância por permutação, importância nativa do *Random Forest*, dependência parcial e uma árvore de decisão substituta (*surrogate tree*).

A primeira análise foi realizada com SHAP (*SHapley Additive exPlanations*), com o objetivo de observar como os atributos contribuíram para a saída do modelo associada à classe Patológica. A Figura 9 apresenta a distribuição dos impactos dos principais atributos sobre a predição da classe 3 no conjunto de teste.




Figura 9. SHAP Summary Plot para a classe 3 (Patológico) no conjunto de teste.

A análise SHAP indica que atributos relacionados à tendência central do histograma e à variabilidade da frequência cardíaca fetal tiveram papel relevante na decisão do modelo para a classe Patológica. Entre os atributos destacados, aparecem *histogram_mean*, *abnormal_short_term_variability*, *histogram_median*, *mean_value_of_short_term_variability* e *percentage_of_time_with....* Esses resultados sugerem que o modelo considera tanto medidas de variabilidade quanto medidas resumidas da distribuição dos batimentos cardíacos fetais para diferenciar casos patológicos.

Além da análise SHAP, foi calculada a importância por permutação no conjunto de teste, utilizando o F2-Score Macro como métrica de avaliação. Esse método mede a queda de desempenho causada pela aleatorização de cada atributo individualmente. A Figura 10 apresenta os atributos mais relevantes segundo esse critério.




Figura 10. Importância por permutação no conjunto de teste, medida pela queda no F2-Score Macro.

Pela importância por permutação, o atributo mais relevante foi *abnormal_short_term_variability*, com importância média de 0.1562. Em seguida, destacaram-se *histogram_mean* (0.1305), *mean_value_of_short_term_variability* (0.1164), *percentage_of_time_with_abnormal_long_term_variability* (0.0754) e *accelerations* (0.0591). Como essa análise é calculada sobre o conjunto de teste e usa a métrica principal do estudo, ela foi considerada a evidência mais direta para ranquear a relevância preditiva dos atributos.

Também foi extraída a importância nativa do próprio *Random Forest*, apresentada na Figura 11. Essa medida indica quais atributos foram mais utilizados internamente pelas árvores para reduzir impureza durante as divisões. Embora seja útil como evidência complementar, ela pode ser menos robusta que a importância por permutação, pois tende a favorecer atributos com maior número de possibilidades de divisão.




Figura 11. Importância nativa dos atributos no modelo *Random Forest*.

A comparação entre a importância por permutação e a importância nativa mostra convergência nos principais atributos. Em ambos os métodos, *abnormal_short_term_variability*, *histogram_mean*, *mean_value_of_short_term_variability* e *percentage_of_time_with(...)* aparecem entre os atributos mais relevantes. Essa concordância aumenta a confiança de que o modelo realmente depende dessas variáveis para realizar a classificação.

Para analisar a direção do efeito dos principais atributos sobre a classe Patológica, foram gerados gráficos de dependência parcial. A [Figura 12](#) mostra como a probabilidade prevista para a classe 3 varia conforme os atributos mais importantes são alterados, mantendo os demais efeitos médios do conjunto de teste.




Figura 12. Dependência parcial dos principais atributos em relação à probabilidade prevista da classe 3 (Patológico).

Os gráficos de dependência parcial complementam as análises de importância, pois ajudam a observar não apenas quais atributos são relevantes, mas também como suas variações afetam a probabilidade prevista de patologia. Essa leitura deve ser feita com precaução, já que a dependência parcial representa um comportamento médio do modelo e não uma relação causal isolada.

Por fim, foi treinada uma árvore de decisão substituta para aproximar o comportamento do *Random Forest*. Essa árvore não substitui o modelo final, mas fornece uma representação simplificada das regras aprendidas. A árvore substituta foi limitada a uma profundidade baixa para preservar legibilidade e obteve fidelidade de aproximadamente 0.922 em relação às predições do *Random Forest* no conjunto de teste.




Figura 13. Árvore de decisão substituta treinada para aproximar as predições do *Random Forest*.

As regras da árvore substituta reforçam a relevância de atributos como *mean_value_of_short_term_variability*, *percentage_of_time_with_abnormal_long_term_variability*, *abnormal_short_term_variability*, *histogram_mean* e *baseline_value*. Como a fidelidade foi alta, essa árvore pode ser utilizada como uma aproximação interpretável do comportamento geral do modelo, embora a decisão final continue sendo produzida pelo *Random Forest* completo.

Em síntese, a interpretação do modelo indica que a classificação depende principalmente de atributos ligados à variabilidade de curto e longo prazo da frequência cardíaca fetal e de medidas estatísticas do histograma do exame de CTG. Esses padrões são coerentes com a natureza do problema, pois alterações nesses atributos podem refletir diferenças importantes entre fetos normais, suspeitos e patológicos.

8 Conclusão

O desenvolvimento do *pipeline* preditivo cumpriu as etapas centrais de modelagem, incluindo remoção de duplicatas, padronização dentro de *Pipeline*, avaliação estratificada, otimização de hiperparâmetros e interpretação do modelo final.

O *spot-checking* estabeleceu um entendimento inicial da aderência do *Gradient Boosting* e do *Random Forest* aos dados, e o subsequente fluxo de otimizações permitiu comparar configurações de forma consistente. Constata-se que o *Random Forest* foi o modelo final mais adequado, por obter o maior F2-Score Macro no conjunto de teste (0.9236). O *Stacking* apresentou desempenho muito próximo (0.9207), mas foi preterido por não superar o *Random Forest* na métrica principal e por apresentar maior complexidade.

O principal desafio desse trabalho ocorreu por conta do alto desbalanceamento de classes. A vasta maioria da classe 1 (Normal) gerou dificuldade de distinção nas fronteiras das classes 2 e 3. No entanto, o uso de ponderação de classes em modelos compatíveis ajudou a mitigar parcialmente esse viés.

8.1 Considerações Éticas no Uso de IA em Saúde

A aplicação de modelos de aprendizado de máquina no diagnóstico médico transcende os desafios puramente técnicos, adentrando uma esfera crítica de ética em Inteligência Artificial [1, 2, 3]. Embora o modelo vencedor deste trabalho tenha apresentado excelente capacidade preditiva, sua potencial implementação no mundo real exige severa cautela.

Primeiramente, a dependência de dados históricos fortemente desbalanceados (como demonstrado na Análise Exploratória) carrega o risco de perpetuar vieses sistêmicos [2]. Se não monitorados, modelos treinados sob essas condições podem resultar em disparidades na qualidade do atendimento às classes minoritárias, ferindo o princípio ético da não-maleficência.

Além disso, a exigência por explicabilidade e transparência algorítmica é inegociável na saúde [1]. O uso de técnicas de explicabilidade nesta pesquisa não é apenas um detalhe técnico, mas sim um passo fundamental para abrir a "caixa preta" dos *ensembles* de árvores, garantindo a prestação de contas (*accountability*) sobre quais variáveis fisiológicas guiaram a detecção da anomalia.

Por fim, diretrizes éticas contemporâneas [3] reforçam a necessidade de que sistemas autônomos de diagnóstico atuem exclusivamente como ferramentas de suporte, sem substituir o julgamento humano. A mitigação de falsos negativos alcançada neste estudo propõe otimizar a triagem de fetos em perigo, mas as predições geradas devem sempre complementar e nunca substituir o julgamento e a responsabilidade final do profissional médico.

Uso de IA

Relatório e Código

Para a realização e escrita do relatório ao longo das etapas T1 e T2, o agente Gemini foi utilizado como ferramenta de suporte para revisão metodológica, correção ortográfica e estruturação e formatação de tabelas em código L^AT_EX. No escopo da programação, agentes de IA (Gemini e OpenAI Codex) auxiliaram na arquitetura do código orientado a objetos (OOP) com *pipeline pattern* e na confecção de gráficos via *Matplotlib* e *Seaborn*, além de dúvidas sobre o funcionamento do *scikit-learn*. Todas as análises, interpretações e decisões metodológicas foram guiadas pelo julgamento crítico dos autores.

A Resultados Detalhados de Validação Cruzada

Tabela 6. Resultados de Acurácia e Recall (CV).

Modelo	Acc (Média)	Acc (Desv)	Rec (Média)	Rec (Desv)
Stacking (RF+GB)	0.9296	0.0110	0.8988	0.0109
Gradient Boosting	0.9361	0.0097	0.8652	0.0224
Random Forest	0.9373	0.0057	0.8539	0.0141
Neural Network	0.9254	0.0105	0.8491	0.0184
Decision Tree	0.9083	0.0063	0.8368	0.0214
Ada Boosting	0.9018	0.0113	0.8129	0.0256
Logistic Regression	0.8639	0.0212	0.8501	0.0235
KNN	0.8923	0.0050	0.7572	0.0270

Tabela 7. Resultados de F1-Score (CV).

Modelo	F1 (Média)	F1 (Desv)
Stacking (RF+GB)	0.8804	0.0230
Gradient Boosting	0.8839	0.0191
Random Forest	0.8828	0.0129
Neural Network	0.8622	0.0218
Decision Tree	0.8424	0.0210
Ada Boosting	0.8306	0.0225
Logistic Regression	0.7807	0.0333
KNN	0.7894	0.0176

Tabela 8. Resultados de F2-Score (CV).

Modelo	F2 (Média)	F2 (Desv)
Stacking (RF+GB)	0.8908	0.0138
Gradient Boosting	0.8721	0.0192
Random Forest	0.8643	0.0093
Neural Network	0.8537	0.0172
Decision Tree	0.8388	0.0202
Ada Boosting	0.8194	0.0235
Logistic Regression	0.8177	0.0281
KNN	0.7689	0.0231

Referências

- [1] Nasarian, E., Alizadehsani, R., Acharya, U. R., & Tsui, K. L. (2023). Designing Interpretable ML System to Enhance Trust in Healthcare: A Systematic Review to Proposed Responsible Clinician-AI-Collaboration Framework.
- [2] Stiglic, G., et al. (2020). Interpretability of machine learning based prediction models in healthcare.

- [3] Jafari, E. (2025). Ethical Considerations in the Deployment of AI in Healthcare Systems. *International Journal of Computational Health and Machine Learning*